

AQUA-ATMOS

Formulation du Problème — Composante Intelligence Artificielle

École Centrale Casablanca — PLBD 35 | Encadrement : Mme K. Zerhouni

X — Entrées du Système

Variable	Description	Unité
Température ambiante	Température de l'air autour du système	°C
Humidité relative	Quantité d'eau contenue dans l'air en pourcentage	%
Température de condensation	Température de la surface froide où l'eau se condense	°C
Température du CaCl_2	Température actuelle du sorbant hygroscopique	°C
Taux de saturation CaCl_2	Pourcentage d'humidité absorbée par le sorbant	%
Puissance solaire disponible	Énergie photovoltaïque instantanée	W
Niveau batterie	Charge de la batterie de stockage	%
Niveau réservoir d'eau	Volume d'eau collecté	%
État & consommation VCRC	On/off du compresseur et puissance électrique consommée	W
Débit d'air	Quantité d'air circulant à travers le système par heure	m ³ /h
Heure & mois	Moment de la journée et période de l'année	—

Y — Sorties du Système

Sortie	Description	Type	Plage
Y_1	Production d'eau prédite dans les 2h	Scalaire	0 – 5 L/h
Y_2	Décision d'activation optimale du VCRC	Binaire	activer / attendre
Y_3	Alerte anomalie système	Binaire	normal / anomalie
Y_4	Durée optimale du cycle VCRC	Scalaire	minutes
Y_5	Alerte régénération CaCl_2	Binaire	régénérer / attendre
Y_6	Score d'efficacité énergétique	Scalaire	0 – 100%

$f : X \rightarrow Y$ — Fonction Cible

À partir des conditions environnementales et de l'état du système en temps réel, le modèle prédit le rendement en eau attendu, recommande les décisions d'activation optimales du VCRC et du CaCl_2 , détecte les anomalies de fonctionnement, et évalue l'efficacité énergétique globale.

Hypothèse ML — Pourquoi l'Apprentissage Automatique ?

Les variables environnementales et l'état du système interagissent de manière **non-linéaire** et varient continuellement dans le temps, rendant impossible l'écriture de règles statiques exhaustives. De plus, les équations physiques seules ne suffisent pas à modéliser le comportement réel du

système : elles ignorent la dégradation progressive du compresseur VCRC, les pertes thermiques du boîtier, et les variations d'état du sorbant. Le modèle d'apprentissage automatique¹ **compense ces écarts** en les apprenant à partir des données mesurées.

Baseline — Méthode de Référence à Dépasser

Système de contrôle à règles fixes basé sur des seuils de température et d'humidité :

- Si $RH > 60\%$ **ET** $T < 35^\circ\text{C}$ **ET** batterie $> 30\%$ → activer VCRC
- Si saturation $\text{CaCl}_2 > 80\%$ → lancer régénération
- Sinon → veille

Déterministe, vérifiable, sans données d'entraînement. Le modèle IA doit démontrer un rendement hydrique énergétique supérieur à cette baseline.

Métrique Principale

$$m = \text{Litres d'eau produits Watt} - \text{heure consommée} \quad (\text{L/Wh})$$

Métriques secondaires : RMSE² sur Y_1 (prédiction de production), taux de détection des anomalies sur Y_3 .

Contraintes Système

Contrainte	Justification	Valeur
Mémoire (RAM)	Déploiement sur ESP32-S3 (TinyML ³ embarqué)	< 512 Ko
Énergie MCU ⁴	Alimentation solaire en territoire isolé	< 0.5 W
Latence	Réactivité de la décision d'activation du VCRC	< 50 ms

¹**Apprentissage automatique (Machine Learning)** : technique permettant à un système informatique d'apprendre des règles à partir de données, sans les programmer explicitement.

²**RMSE** (Root Mean Square Error) : indicateur qui mesure l'écart moyen entre les valeurs prédites par le modèle et les valeurs réelles mesurées.

³**TinyML** : branche de l'IA permettant d'exécuter des modèles d'apprentissage automatique directement sur des microcontrôleurs à faible consommation énergétique, sans recours au cloud.

⁴**MCU** (Microcontroller Unit) : microcontrôleur, petit processeur embarqué dans le prototype chargé de lire les capteurs et exécuter le modèle IA.